

基于可解释性优化堆叠模型的风电功率预测

戚焕兴^{1,2}, 卓毅鑫¹, 李 凌¹, 殷林飞³, 秦意茗¹, 蒙文川⁴

(1. 广西电网有限责任公司电力调度控制中心, 南宁 530023; 2. 广西电网有限责任公司北海供电局, 北海 536000;
3. 广西大学电气工程学院, 南宁 530004; 4. 南方电网能源发展研究院有限责任公司, 广州 511458)

摘 要: 鉴于当前风电功率预测算法在堆叠建模过程所存在试错性与弱解释性问题, 提出一类应用于风电功率预测的可解释性优化堆叠模型 (interpretable optimal stacking model, IOSM)。首先, 建立初始冗余基学习器并进行特征权重解释; 其次, 构建一个综合衡量模型性能与计算代价的特征优化度量, 优化关键特征并训练形成优化后的基学习器; 最终, 根据特征优化度量对基学习器进行优化选择, 搭建得到元学习器。经如上步骤, 即完成搭建 IOSM。所提算法在广西典型风电场的算例表明, IOSM 相对于最优单一模型的 RMSE 与 MAE 指标上分别降低 13.01% 和 18.23%; 相对于其他各类主流组合预测算法, 该元算法在 RMSE 与 MAE 指标分别降低 8.24% 与 10.28% 的同时, 至少降低了 142.38% 的建模计算代价。所提算法的有效性及其先进性得到验证, 为风电功率预测的可解释性优化建模上提供了新的思路与方法。

关键词: 风电功率预测; 可解释性; 堆叠模型; 特征优化; 集成学习

中图分类号: TM614

文献标志码: A

0 引 言

近年来, 风电装机日益攀升, 截至 2024 年底, 中国风电累计装机容量超 56126 万 kW, 同比增长 18.13%^[1]。风力发电主要利用近地风能进行发电, 具有波动性大、随机性强、可控性弱等特点^[2], 其功率的反调峰特性、非周期性分量对电力系统的调度和安全稳定运行带来严峻挑战^[3-4], 提高风电功率预测 (wind power forecasting, WPF) 准确率对保障电力系统安全、稳定、经济运行具有重要意义^[5]。

国内外学者对提升短期风电功率预测准确率开展了大量研究工作, 目前, 短期风电功率预测算法主要分为物理方法和统计方法两大类。物理方法一般通过风电场位置、地形、地貌和风电机组信息等静态信息为依据, 模拟风电场风能资源分布及转化过程执行预测。统计方法通过对风电场历史运行信息进行数据挖掘与数理统计完成建模并执行预测, 其典型模型主要包括有以循环神经网络 (recurrent neural network, RNN)、卷积神经网络 (convolutional neural network, CNN)、DBN (deep belief networks, DBN) 为代表的深度学习 (deep learning, DL) 模型^[6-7]; 以支持向量机 (support vector machine, SVM)、K 近邻算法 (k-nearest neighbor, KNN)、随机森林算法 (random forest, RF) 为代表的机器学习 (machine learning, ML) 模型^[8-9] 和以 ARIMA 模型 (auto-regressive integrated moving average model) 系列算法为代表的时序

模型 (time series, TS) 等^[10]。单一的预测模型无法良好适配各类风电运行工况, 存在较大局限性^[11]。近年来, 融合不同模型优点的组合预测算法成为主流, 对模型的预测准确率与鲁棒性有较显著的提高作用^[12], 主要可分为多模型加权组合预测、序列融合组合预测、模型架构改进组合预测共 3 类^[13]。

例如, 文献[14]采用博弈论方法, 基于纳什均衡计算单一模型的组合权重, 达到各模型博弈最优预测的效果; 文献[15]提出利用交叉熵理论判断各预测方法的相互交叉程度, 按支撑度大小变化动态优化模型权重达到更优预测准确率; 文献[16-17]分别通过经验模态分解 (empirical mode decomposition, EMD) 和变分模态分解 (variational mode decomposition, VMD) 对各分解子序列分别进行预测并重构, 降低了不平稳信号序列的预测难度; 文献[18-19]结合循环神经网络和卷积神经网络的优点, 以模型自身架构的改进组合促进模型精度提升; 文献[20-22]将 ARIMA 模型结合机器学习模型进行了融合尝试, 在短期与超短期预测准确率上有所提升。

上述研究通过不同的组合预测形式, 均一定程度上提高了风电功率预测准确率。然而, 其仍缺乏对基础模型或基础序列的模型解释与优化, 具有试错性。预测性能上限受基础模型限制, 易陷入局部最优; 且所建立模型均缺乏对于预测准确率与建模代价的均衡考虑, 亦导致组合模型的逐渐趋于冗余。

收稿日期: 2024-12-27

基金项目: 广西电网公司科技项目 (046000KK52220007)

通信作者: 蒙文川 (1976—), 男, 博士、高级工程师, 主要从事新能源规划及并网运行方面的研究。mengwc@csg.cn

因此,本文提出一类可解释性优化堆叠模型(IOSM)。所提模型为基学习器层和元学习器层首尾相接的堆叠模型,具体建模思路为:在基学习器层中,采用模型可解释性(model interpretability, MI)算法对其特征重要程度进行解释,建立衡量模型性能和代价的特征优化度量,优化关键特征建模以优化基学习器;类似地,在元学习器层中,对各基学习器的重要程度进行解释,根据特征优化度量地优化基学习器以优化元学习器。经此过程,本文算法将在模型构成上实现对模型特征和基础模型的双重优化;在模型评价指标上,实现对模型性能与代价上的双重优化,缓解了建模过程中预测性能最大化和模型冗余最小化的矛盾。

1 理论基础

本节对本文中所运用到的理论基础进行介绍,即堆叠模型原理与文中所运用到的模型可解释性算法原理。

1.1 堆叠模型原理概述

堆叠模型(stacking model, SM)一般采用集成学习(ensemble learning, EM)方法实现^[23],即通过组合多个独立模型来提高预测准确率,其核心在于构造多个差异化的预测结果^[24],并采取适当的策略结合各个预测结果实现组合预测。通常具有两层结构,分别为基学习器(base learner, BL)和元学习器(meta learner, ML)。第1层中各基学习器的输出作为第2层元学习器的输入,堆叠形成最终模型。堆叠模型的一般架构见图1。




图1 堆叠模型的一般架构

Fig. 1 General architecture of stacking model

其模型的数学表达可归纳如下式,对于基学习器,有:

$$Y_i = f_i(X_1, X_2, \dots, X_n) \quad (1)$$

式中: Y_i ——第*i*个基学习器的模型输出值; X ——该基学习器的特征输入; f_i ——该基学习器的响应特性函数。

$$O_m = f_m(Y_1, Y_2, \dots, Y_n) \quad (2)$$

式中: O_m ——元学习器的模型输入值; Y ——特征输入,即基学习器的输出; f_m ——该元学习器的响应特性函数。

从堆叠的思路上看,考虑基学习器之间一般具有不同的“归纳偏好”,通过元学习器整合之后,得到的最终预测结果的方差会整体降低,从而提升预测准确率。

1.2 模型可解释性算法

本文中,采用模型无关的局部解释(local interpretable model-agnostic explanations, LIME)算法对各模型进行解释,为保证文章的完整性与可读性,以下对LIME算法原理作简要介绍。

1.2.1 LIME 算法概述

LIME 算法是由 Marco Túlio Ribeiro 等^[25]于2016年提出的一种黑箱解释算法,该算法针对黑箱局部的响应特性进行模拟,根据实例扰动后的数据点距离原始数据点的距离分配权重,最终学习到黑箱模型的解释模型,并获取特征权重系数。

1.2.2 LIME 算法的基本原理

对于任意复杂模型 f ,因模型本身较高的复杂度,单一可解释性模型对复杂模型全部特征的全局代理(global surrogate, GS)的效果往往欠佳^[26]。因此,在LIME算法中,将该种解释定义为一个简单模型对复杂模型的局部代理(local surrogate, LS),因此基于LIME的解释器具备较好的可解释性(interpretability)、局部保真度(local fidelity, LF)和与模型无关性(model agnostic, MA)。即对于任意的复杂模型 f ,其响应特性函数定义为 $f(\cdot)$,在解释其在某一实例的特征重要性时,定义一个与 f 无关的、可解释的解释器 $g \in G$,其响应特性函数定义为 $g(\cdot)$, $g(\cdot)$ 待求解,当求解出一个可解释的 g ,即可完成对模型的局部解释,即确定了其输入特征与输出响应的规则与偏好。

2 基于可解释性优化堆叠模型的风电功率预测算法

基于以上理论基础及研究背景,本文提出一类可解释性优化堆叠模型(interpretable optimal stacking model, IOSM),应用于风电功率预测建模。

算法的核心思想体现在两方面:

1)可解释性:结合模型可解释性算法(本文采用LIME算法),使在特征及基学习器的优化与选择上具可解释性;

2)特征优化度量:构造均衡计算代价与模型性能的特征优化度量,以合理指标指导模型的堆叠与优化。

2.1 构造IOSM特征优化度量

不难求得各个基学习器、元学习器及其相关特征的LIME解释权重。此时,还需解决根据LIME权重确定合适的输入特征的问题。该问题可描述为:

$$f = \text{model}(X_w(\theta)) \quad (3)$$

式中: f ——所搭建的预测模型; $\bar{w}$ —— f 的平均权重系数向量; θ ——特征甄选优化的权重阈值; $X_w(\theta)$ ——基于 $\bar{w}$ 和 θ 甄选出的输入特征向量,model表示某一类初始模型。当 $\bar{w}$ 中的某元素高于 θ , f 保留该元素作为模型的输入;否则剔除。式(3)描述了模型的特征优化过程。

在此,本文定义 $E(\cdot)$ 为模型 f 的特征优化度量:

$$E(f) = C(f) + kP(f), k \in (0, +\infty) \quad (4)$$

式中: $C(f)$ ——代价指标, 表征求解模型 f 的计算代价, 即建模计算代价, $C(f)$ 越小, 代价越小; $P(f)$ 是性能指标, 表征模型 f 的性能, $P(f)$ 越小, 性能越优; k ——权系数, 决定所建模型对性能和计算代价的偏好程度, 一般以 $k^* = \frac{\max(C(f)) - \min(C(f))}{\max(P(f)) - \min(P(f))}$ 为基准上下浮动取值, 建议在 $[0.25k^*, 4k^*]$ 内取值, 当 k 取 k^* , 即表示此时对建模计算代价与模型性能的偏好均衡, k 越大, 该度量对 $P(f)$ 的偏好程度就越大。当 $E(f)$ 有最小值, 建立模型 f 的代价小而性能高, 即求得最优模型 k^* 。

进一步地, 定义代价指标:

$$C(f) = \sqrt{\frac{\dim(X_f)}{\dim(X_r)}} \times V_{\text{FLOPs}}(f) \quad (5)$$

式中: $\dim(X_f)$ —— f 的特征维数, $\dim(X_r)$ 是模型的冗余特征维数, 二者比值定义了模型的空间复杂度; $V_{\text{FLOPs}}(f)$ ——模型单次训练所需的浮点运算次数 (floating point of operations, FLOPs), 对应时间复杂度, GFLOPs。

定义性能指标:

$$P(f) = E_{\text{RMSE}}^*(f) = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i^* - y_i^*)^2} \quad (6)$$

式中: E_{RMSE}^* ——模型 f 在验证集中的 RMSE, 上标*代表标么; $\hat{y}_i^*$ ——第 i 个模型预测值; y_i^* ——模型预测值对应的实际值。本文中的代价指标和性能指标并不局限于上式, 对于不同应用实例, 可对式(5)和式(6)中的构成作适应性改动, 如式(5)中的 $V_{\text{FLOPs}}(f)$ 也可用乘加累积操作数 (multiply accumulate operations, MACs) 作为时间复杂度指标, 式(6)可用 MAE 作为性能指标等, 其在优化效果上相似, 但在具体数值上有一定差异, 将对模型性能和计算代价的基础偏好有不同影响。

2.2 基于 IOSM 的风电功率预测算法流程

结合 2.1 节中的依据, 基于可解释性和多模型堆叠优化的风电功率预测算法流程可归纳如下:

- 1) 获取风电场功率预测的基础建模数据, 构造可能成为风电出力影响因素的特征, 形成冗余特征数据集;
- 2) 以冗余特征数据集为训练集, 训练多个适用性强且差异化高的基学习器模型 (第一次);
- 3) 对步骤 2) 中的基学习器的输入特征分别进行 LIME 解释, 得到基学习器的平均权重向量 $\bar{w}_b$;
- 4) 设定步长为 s_b 的 θ_b 向量, θ_b 的取值范围应为 $[0, 1]$, 根据式(1)搭建基学习器 (第 2 次), 根据式(4)~式(6)评估基学习器优劣, 保留性能最优的基学习器;
- 5) 将基学习器的输出连接与元学习器的输入, 建立元学习器模型 (第 1 次);
- 6) 对步骤 5 中元学习器的输入特征进行 LIME 解释, 得到基学习器的平均权重向量 $\bar{w}_m$;
- 7) 设定步长为 s_m 的 θ_m 向量, 根据式(6)搭建元学习器

(第 2 次), 根据式(4)~式(6)评估基学习器优劣, 保留性能最优的元学习器, IOSM 建模完成, 模型架构参见图 2。




图2 基于 IOSM 的风电功率预测模型

Fig. 2 wind power forecasting model based on IOSM

其中, 经特征优化度量建立高质量的基学习器和元学习器是算法的关键, 本文采用遍历迭代求解最优指标及模型。经该方法建模, 将能以相对小的建模代价下达到较优的模型预测性能, 整体提升所建立模型的优质性。

3 算例分析

3.1 评价指标

本算例均采用采用式(4)~式(6)作为特征优化度量, 为验证本文所提算法的有效性, 且为统一评价量纲, 以标么化的均方根误差 (E_{RMSE}^*) 和平均绝对误差 (E_{MAE}^*) 作为模型的性能评价指标, 其基准值是风电场容量; 以单次模型训练的浮点运算次数 V_{FLOPs} 代价指标, 单位: GFLOPs。

3.2 IOSM 的搭建

3.2.1 基学习器的搭建、解释与优化

此部分为搭建模型的第 1 阶段, 主要任务是搭建多个可能适用于的基学习器, 构成堆叠模型的第 1 层。

1) 基础数据及其冗余处理

以广西某甲、乙风电场数据作算法训练建模的数据基础; 时间跨度为 2021 年 9 月 1 日 00:00 至 2023 年 8 月 30 日 23:45, 时间分辨率为 15 min, 初始的训练数据包括: 模型输入训练数据共有包括风速、风向、湿度、温度、气压 5 类在内的实测气象数据和数值天气预报 (numerical weather prediction, NWP) 数据; 模型的输出训练数据则为风电场的实测功率。以 2021 年 9 月 1 日至 2023 年 7 月 30 日的数据作为训练集, 2023 年 8 月 1 日至 8 月 31 日的数据作为验证集。

冗余特征的构造以风机出力的物理影响因素作为指导依据,风电出力的物理决定式为:

$$P_v = \frac{1}{2} \rho V^3 \pi R^2 C_p \quad (5)$$

式中: P_v ——叶轮吸收的风能功率, MW; ρ ——空气密度, kg/m³; V ——风电机组轮毂高度风速, m/s; R ——叶轮风面的半径, m; C_p ——叶轮的功率系数。

可见,风力机输出功率与风电机组轮毂高度风速的三次方呈正比;与空气密度呈正比,空气密度受气压、温度影响,其关系式为:

$$\rho = \frac{p}{p_{\text{amt}}} \times \frac{273.15}{T} \quad (8)$$

式中: p ——大气压强, hPa; p_{amt} ——标准大气压强, 其数值为 1.013×10^3 hPa; T ——温度, K。

此外,在温度的情况下,由于水汽压分担了空气中的大气压强,空气密度随相对湿度的增大而减小,即有:

$$\rho \propto \varphi^{-1} \quad (9)$$

由式(5)~式(7)可知,与风电功率相关的直接影响因素

有风速的三次方、风向的正弦及余弦值、大气压、温度的负一次方、相对湿度的负一次方等,构造得到冗余特征向量可表达为:

$$X_r = [VD_w T \varphi P V^2 V^3 \sin(D_w) \cos(D_w) T^{-1} \varphi^{-1}]^T \quad (10)$$

式中: D_w ——风向, (°); φ ——相对湿度。综上,基学习器的模型冗余特征构建完成。

2) 初始基学习器的搭建

首先对所搭建的基学习器的类别及主要参数进行说明。

考虑采用性能良好且差异化的基学习器搭建 IOSM 的第 1 层,包含机器学习模型、非时序的深度学习模型、时序的深度学习模型等 3 类模型,包括:①典型机器学习模型:SVM、KNN、RF;②非时序的深度学习模型:MLP、RBF、DBN;③时序的深度学习模型:RNN、LSTM、NARX。

3) 基学习器的解释

进一步,对所搭建的基学习器分别进行 LIME 解释,经求解,各基学习器的特征权重系数(标么化)如表 1 所示,表征了各特征对模型输出的贡献。

表 1 基于 LIME 的各基学习器特征权重系数

Table 1 Feature weight coefficient of each base learner based on LIME

基学习器 类目	w_V	w_{D_w}	w_T	w_φ	w_P	w_{V^2}	w_{V^3}	$w_{\sin(D_w)}$	$w_{\cos(D_w)}$	$w_{T^{-1}}$	$w_{\varphi^{-1}}$
SVM	0.97	0.31	0.07	0.04	0.08	0.89	1.00	0.41	0.36	0.07	0.05
KNN	0.93	0.32	0.1	0.01	0.12	0.84	1.00	0.42	0.43	0.17	0.02
RF	0.95	0.4	0.08	0.02	0.13	0.93	1.00	0.43	0.41	0.08	0.04
MLP	0.93	0.37	0.12	0.01	0.14	0.87	1.00	0.42	0.40	0.13	0.02
RBF	1.00	0.43	0.09	0.04	0.11	0.85	0.97	0.46	0.47	0.16	0.08
DBN	0.92	0.41	0.09	0.03	0.13	0.89	1.00	0.45	0.42	0.14	0.03
RNN	1.00	0.43	0.12	0.04	0.15	0.91	1.00	0.47	0.48	0.15	0.07
LSTM	1.00	0.45	0.13	0.05	0.13	0.90	0.92	0.48	0.47	0.22	0.10
NARX	0.97	0.43	0.12	0.03	0.15	0.88	1.00	0.49	0.46	0.13	0.05
平均	0.96	0.39	0.10	0.03	0.13	0.88	0.99	0.45	0.43	0.15	0.05




图 3 基于 LIME 的各基学习器特征权重系数簇形图

Fig.3 Feature weight coefficient comparison diagram of each base learner based on LIME

4) 基学习器的优化

对于所搭建的 9 个初始基学习器,分别计算其 $E(f)$,进行模型输入的优化。各基学习器的优化算法一致,在此,以 MLP 模型为例,介绍其优化过程,设定 s_b 为 0.05、取值范围为 $[0, 0.5]$ 的 θ_b 向量, k 分别取 $0.25k_b^*$ 、 $0.5k_b^*$ 、 k_b^* 、 $2k_b^*$ 、 $4k_b^*$ 以作对比,计算得 $k_b^* = 6$;根据式(2)~式(4)计算其 $E(f)$,各阈值下的特征优化度量详见表 2,可见,不同 k 值下的最优 $E(f)$ 呈对角线分布,即随着 k 由小增大,模型的偏好逐渐由较低建模计算量下的较佳性能寻优转向更高建模计算量下的更佳性能寻优,该分布亦印证了原式的预设,考虑在风电功率问题上,模型预测性能更具重要性,最终取 $k = 2k_b^* = 12$,此时当 $\theta_b = 0.10$, $\dim(X_f) = 8$, $E(f) = 1.735$ 为最优值,组合 8 个权

重最大的特征得到特征向量为 $X_{\text{opMLP}} = [VD_w PV^2 V^3 \sin(D_w) \cos(D_w) T^{-1}]^T$ 。据此,再次对 MLP 再次进行建模,此即完成了堆叠模型的第 1 层优化。对于其他基学习器的优化亦参考此示例。

表 2 不同阈值下的基学习器的特征优化度量

Table 2 Feature optimization measures of base learners under different thresholds

θ_b	$E(f)_{k=1.5}$	$E(f)_{k=3}$	$E(f)_{k=6}$	$E(f)_{k=12}$	$E(f)_{k=24}$	$C(f)$	$P(f)$	$V_{\text{FLOPs}}(f)$	$\frac{\dim(X_f)}{\dim(X_r)}$	$\dim(X_f)$	$\dim(X_r)$
0	0.575	0.749	1.097	1.793	3.185	0.401	0.116	0.161	1.000	11	11
0.05	0.513	0.695	1.058	1.784	3.236	0.332	0.121	0.121	0.909	10	11
0.1	0.443	0.628	0.997	<u>1.735</u>	3.211	0.259	0.123	0.092	0.727	8	11
0.15	0.386	0.587	0.989	1.793	3.401	0.185	0.134	0.063	0.545	6	11
0.2	0.386	0.587	0.989	1.793	3.401	0.185	0.134	0.063	0.545	6	11
0.25	0.386	0.587	0.989	1.793	3.401	0.185	0.134	0.063	0.545	6	11
0.3	0.386	0.587	0.989	1.793	3.401	0.185	0.134	0.063	0.545	6	11
0.35	0.365	0.586	1.027	1.909	3.673	0.145	0.147	0.046	0.455	5	11
0.4	0.365	0.586	1.027	1.909	3.673	0.145	0.147	0.046	0.455	5	11
0.45	0.359	0.644	1.214	2.354	4.634	0.074	0.190	0.020	0.273	3	11
0.5	0.359	0.644	1.214	2.354	4.634	0.074	0.190	0.020	0.273	3	11
最优值	0.359	0.586	0.989	<u>1.735</u>	3.185	0.197	0.143	0.020	0.273		

3.2.2 元学习器的搭建、解释与优化

此部分是搭建模型的第 2 阶段,对多个基学习器进行元回归训练建模,形成堆叠模型的第 2 层。

1) 元学习器的搭建

元学习器的训练数据由各基学习器的输出与风电功率实际值作组合而成。考虑实际应用中风电场可能存在数据缺失问题,非时序网络不因数据连续性问题影响建模与预测,相较于时序网络作为元学习器更稳定,且在先前所单一模型的对比显示(表 3),DBN 的最佳的非时序网络,因此采用 DBN 作为元学习器(基础模型参数见附录表 1)。DBN 是由多个受限玻尔兹曼机(restricted boltzmann machine, RBM)堆叠而成的多层神经网络,其基于对比散度的无监督训练过程使其尽可能地保留原始特征的特点,进一步,通过有监督拟合训练达到更优预测效果。本研究中的元学习器以多个风电预测值作为输入,拟合风电实际值,DBN 模型特性亦决定其较适合于本研究中的元学习建模。

2) 元学习器的解释

对所搭建的元学习器进行基于 LIME 算法的解释。元学习器对各基学习器的权重系数(标么化)及各评价指标见表 3,表征了各基学习器对元学习器输出的贡献。

3) 元学习器的优化

对于所搭建元学习器进行优化,设定 s_m 为 0.02、范围为 $[0.85, 0.97]$ 的 θ_m 向量, k 分别取 $0.25k_m^*$ 、 $0.5k_m^*$ 、 k_m^* 、 $2k_m^*$ 、 $4k_m^*$ 以作对比,计算得 $k_m^* = 60$;根据式(4)~式(6)计算其 $E(f)$,各阈值下的模型优化依据详见表 4,可见,不同 k 值下的最优 $E(f)$ 呈对角线分布,即,随着 k 由小增大,模型的偏好逐渐由较低

表 3 基于 LIME 的元学习器特征权重系数表

Table 3 Feature weight coefficient of meta learner based on LIME

基学习器	w_{ML}	$E_{\text{RMSE}}^*/\text{pu}$	$E_{\text{MAE}}^*/\text{pu}$
SVM	0.90	0.12	0.10
KNN	0.88	0.14	0.11
RF	0.85	0.13	0.12
MLP	0.93	0.12	0.091
RBF	0.87	0.15	0.12
DBN	0.95	0.11	0.093
RNN	0.89	0.12	0.10
LSTM	0.91	0.11	0.10
NARX	1.00	0.10	0.082
平均	0.91	0.12	0.091

建模计算量下的较佳性能寻优转向更高建模计算量下的更佳性能寻优,该分布亦印证了原式的预设,考虑在风电功率问题上,模型预测性能更具重要性,最终取 $k = 2k_m^* = 120$,当 $\theta_m = 0.89$, $\dim(X_f) = 8$, $E(f) = 9.40$ 为最优值,组合 6 个权重最大的基学习器得到元学习器的输入特征向量为 $X_{\text{opDBN-ML}} = [\int_{\text{SVM}} \int_{\text{MLP}} \int_{\text{DBN}} \int_{\text{RNN}} \int_{\text{LSTM}} \int_{\text{NARX}}]^T$ 。根据新的特征数据集,对该 DBN 进行建模,此即完成了堆叠模型的第 2 层优化。

至此,一个完整的可解释性优化堆叠模型训练完毕。

表 4 不同阈值下的元学习器的性能指标

Table. 4 Performance indicators of meta learner under different thresholds

θ_m	$E(f)_{k=15}$	$E(f)_{k=30}$	$E(f)_{k=60}$	$E(f)_{k=120}$	$E(f)_{k=240}$	$C(f)$	$P(f)$	$V_{\text{FLOPs}}(f)$	$\frac{\dim(X_f)}{\dim(X_r)}$	$\dim(X_f)$	$\dim(X_r)$
0.85	2.398	3.747	6.444	11.838	22.626	1.050	0.0899	1.102	1.000	9	9
0.87	2.216	3.542	6.194	11.498	22.106	0.890	0.0884	0.891	0.889	8	9
0.89	2.044	3.379	6.049	<u>11.389</u>	22.069	0.709	0.0890	0.753	0.667	6	9
0.91	1.922	3.288	6.021	11.487	22.419	0.555	0.0911	0.694	0.444	4	9
0.93	1.863	3.291	6.147	11.859	23.283	0.435	0.0952	0.568	0.333	3	9
0.95	1.780	3.268	6.244	12.196	24.100	0.292	0.0992	0.384	0.222	2	9
0.97	1.683	3.231	6.327	12.519	24.903	0.135	0.1032	0.163	0.111	1	9
最优值	1.683	3.231	6.021	<u>11.389</u>	22.069	0.135	0.0884	0.163			

3.3 IOSM与其他模型的对比分析

为验证本文所提算法的有效性,本文现将本文算法与 9 种单一模型和 3 种组合模型进行对比,模型的评价指标见 3.1 节,建模的数据基础见 3.2 节,算例的对比预测时长为 7 d,时间分辨率为 15 min。

其中:3.3.1 节分析第 1 层优化的对性能提升的有效性;3.3.2 节分析第 2 层优化的对性能提升的有效性;3.3.3 节分析模型优化对性能和效率的整体提升的有效性,评估本文算法的是否具有先进性。

3.3.1 优化基学习器与非优化基学习器的对比分析


本小节将 3.2 节中所搭建并特征优化的 MLP 模型与初始 MLP 模型、冗余 MLP 模型作性能对比,对比的指标有 E_{RMSE}^* 、 E_{MAE}^* 。为控制变量,初始 MLP 模型的输入特征向量为初始气象要素;冗余 MLP 模型的输入特征向量见式(8)。

经计算,各模型的预测对比如表 5 与图 4 所示,从图 4 可看出,优化 MLP 的预测值与后验的实际功率拟合性最高,明显优于初始 MLP,亦略优于冗余 MLP。从表 5 看出,优化 MLP 各评价指标明显优于初始 MLP,且略优于冗余 MLP,体现了去冗余对模型性能仍可能有有利影响。IOSM 算法下的 MLP 具有更低的模型复杂度,且具有更优预测水平。印证了本文算法中的第 1 层优化的对性能提升的有效性。


表 5 基学习器间的性能对比分析

Table. 5 Performance comparison between base learners

模型	甲风电场		乙风电场	
	$E_{\text{RMSE}}^*/\text{pu}$	$E_{\text{MAE}}^*/\text{pu}$	$E_{\text{RMSE}}^*/\text{pu}$	$E_{\text{MAE}}^*/\text{pu}$
初始 MLP	0.183	0.132	0.192	0.133
冗余 MLP	0.158	0.114	0.161	0.120
优化 MLP	0.151	0.109	0.152	0.115



a. 甲风电场



b. 乙风电场

图 4 优化前后的基学习器的风电功率预测对比

Fig. 4 Comparison of wind power forecasting between pre and post optimal base learners

3.3.2 优化堆叠模型与基学习器的对比分析


本小节将 3.2 节中所搭建的优化堆叠模型与 9 类单一模型(基础模型参数见附录 1)的作对比分析,对比情况见表 6 与图 5,从图像上,可见,本文算法模型的预测值与后验的实际功率的拟合性最高;从具体数值指标看,本文算法相较最优单一模型的 E_{RMSE} 指标降低了 13.01%,在 E_{MAE} 指标上降低了 18.23%。

表6 IOSM与其他单一模型的性能指标对比


Table. 6 Performance indicators comparison between IOSM and other single models

模型		甲风电场		乙风电场	
		E_{RMSE}^*/pu	E_{MAE}^*/pu	E_{RMSE}^*/pu	E_{MAE}^*/pu
机器学习模型	SVM	0.141	0.102	0.142	0.122
	KNN	0.171	0.114	0.211	0.12
	RF	0.158	0.120	0.154	0.105
非时序的深度学习模型	MLP	0.151	0.109	0.152	0.115
	RBF	0.172	0.122	0.172	0.12
	DBN	0.140	0.094	0.141	0.103
时序的深度学习模型	RNN	0.165	0.109	0.163	0.110
	LSTM	0.152	0.106	0.154	0.101
	NARX	0.136	0.090	0.133	0.102
IOSM(本文模型)		0.114	0.074	0.120	0.083

可见,对于各类单一模型,堆叠模型的第2层优化对预测准确率的提升效果是显著的,降低了单一模型的因适配性、



a. 甲风电场



b. 乙风电场

— IOSM(本文算法) — 单一DBN模型 — 单一NARX模型
— 单一SVM模型 — 实际功率

图5 可解释性优化堆叠模型与单一模型的风电功率预测对比

Fig. 5 Comparison of wind power forecast between IOSM and other single models

随机性问题造成的系统预测误差,强化了模型的整体泛化能力与鲁棒性。

3.3.3 IOSM 与其他组合预测模型的对比分析

进一步地,本文算法将与其他基于模型融合的风电功率预测算法作对比,对比的指标有 E_{RMSE}^* 、 E_{MAE}^* 、 V_{FLOPs} 。对于模型的先进性的评价原则为:1)优先对比性能指标,当模型的性能指标更优则模型更优;2)其次考虑代价指标,在相近的性能指标下,模型的性能指标更小则模型更优。

考虑融合模型算法的多样性,本文算法(IOSM)将分别与文献[15]中的基于交叉熵的加权预测模型(CET-WCM),文献[16]中的结合经验模态分解的 LSTM 模型(EDM-LSTM)、文献[18]中的 CNN-LSTM&GRU 模型作预测对比分析。3种对比算法分别属于加权组合预测类算法、融合组合预测类算法和基础模型改进的组合预测类算法,覆盖目前主流组合预测算法的主要类型。评价指标对比如表7所示。模型的预测对比如图6所示。

表7 IOSM与其他组合预测模型的评价指标对比

Table. 7 Comparison of evaluation indicators between IOSM and other combined forecasting models


算法	甲风电场			乙风电场		
	E_{RMSE}^*/pu	E_{MAE}^*/pu	$V_{FLOPs}/GFLOPs$	E_{RMSE}^*/pu	E_{MAE}^*/pu	$V_{FLOPs}/GFLOPs$
EMD-LSTM	0.149	0.104	19.32	0.152	0.118	12.94
CET-WCM	0.125	0.082	65.85	0.130	0.093	67.12
CNN-LSTM&GRU	0.145	0.112	73.39	0.141	0.109	71.25
IOSM(本文)	0.114	0.074	26.42	0.120	0.083	29.13

1)各模型在性能指标方面的对比分析


结合预测图像分析性能指标,同为加权组合预测的 IOSM 与 CET-WCM,因具备相仿的基学习器,其预测结果在

趋势上呈现出一定相似性,二者在不同时间段的预测结果互有优劣,但 IOSM 整体更趋近于实际功率;而同为以循环神经网络模型为基底的 EMD-LSTM 与 CNN-LSTM&GRU 在曲线

走势上亦存在一定的相似性,预测效果与实际功率均有较明显偏差。



a. 甲风电场



b. 乙风电场

— IOSM(本文算法) — EMD-LSTM — CET-WCM
- - - CNN-LSTM&GRU — 实际功率

图6 本文算法与其他组合预测算法的风电功率预测对比

Fig. 6 Comparison of wind power forecasting between algorithm in this paper and other combined algorithms

表7中的性能指标统计结果亦印证了对图6的观察分析,IOSM与CET-WCM明显优于EMD-LSTM与CNN-LSTM&GRU,IOSM的 E_{RMSE} 与 E_{MAE} 相对于CNN-LSTM分别降低8.24%与10.28%,体现了可解释性优化与交叉熵理论对基础模型优化堆叠的理论优势,同时,IOSM的性能指标仍略优于CET-WCM,可解释性优化堆叠算法相对于一般加权组合预测算法仍体现出优质性。而属EMD-LSTM一类的基于序列分解与重构的融合预测算法仅能做到对序列进行降噪,本质上还是一种单一模型预测,并不具备多模型优化特性,CNN-LSTM&GRU结合了CNN与RNN在模型架构的双重优点,但其组合仍是对模型架构的尝试改进,但仍为单一预测输出的模型,亦不具备多模型优化特性。

2) 各模型在代价指标方面的对比分析

进一步地,对比性能指标相近的IOSM与CET-WCM的代价指标进行对比分析。IOSM与CET-WCM均选取3.2.1中所提到的9类模型作为基学习器,仅在模型的优化组合预测上有不同。从表6看,CET-WCM的建模代价相较IOSM高

142.38%。

IOSM在建模时即对各模型输入进行解释与优化选择,在保证模型性能的前提下简化了模型的复杂度。而CET-WCM一类的算法需先计算出 n 个模型在某一点的预测值,再对 n 个结果进一步进行优化加权,其基础模型无法简化。因此,IOSM的代价指标更优。

综上,本文所提算法及所搭建的IOSM模型优于所对比的其他组合预测算法,模型的优质性与先进性得到验证。

4 结 论

综上,本文提出一类可解释性优化堆叠模型,结合模型可解释性算法对堆叠模型进行特征权重解释,依据所构建的特征优化度量,综合优化各基学习器与元学习器的预测性能和建模计算代价,搭建形成IOSM模型,应用于风电功率预测,为风电功率预测的可解释性优化建模上提供了新思路与方法,解决了堆叠模型在建立过程中存在的试错性与弱解释性等问题。

本文算法在对广西典型风电场的建模预测算例结果中显示:

1)相较于各类模型本身,应用本文算法作优化后,各单一模型(基学习器)与组合模型(堆叠模型)的预测性能均较显著提升,计算代价显著下降,本文算法对基础模型优化的有效性得到验证;

2)相较于各类基于其他原理的组合预测算法,本文算法的预测性能得到了一定程度的提升,且计算代价显著下降,本文算法对比其他原理算法的优质性与先进性得到验证。

此外,本文所提出的可解释性优化堆叠模型并不局限于风电功率预测问题,在建立其他堆叠模型时(如光伏功率预测),亦可参考该算法及其思想,通过对特征、基学习器和元学习器的解释与优化,达到更优的建模效果。下一步,笔者将继续结合该算法对于多时空尺度的新能源功率预测问题展开应用实践。

[参考文献]

- [1] 中国可再生能源学会风能专业委员会. 2024年中国风电吊装容量统计简报[J]. 风能, 2025(3): 1-16.
CWEE. Statistical brief report on wind power hoisting capacity in China in 2022[J]. Wind energy, 2023(4): 40-56.
- [2] WANG N, ZHOU K P, WANG K, et al. Climate change characteristics of coastal wind energy resources in Zhejiang Province based on ERA-interim data [J]. Frontiers in physics, 2021, 9: 720533.
- [3] 盛四清, 俞可, 张文朝, 等. 大规模风电并网对送端系统功角稳定的影响研究[J]. 电力系统保护与控制, 2022, 50(6): 82-90.

- SHENG S Q, YU K, ZHANG W C, et al. Influence of large-scale wind power grid connection on the power angle stability of the sending end system [J]. Power system protection and control, 2022, 50(6): 82-90.
- [4] 薛禹胜, 雷兴, 薛峰, 等. 关于风电不确定性对电力系统影响的评述[J]. 中国电机工程学报, 2014, 34(29): 5029-5040.
- XUE Y S, LEI X, XUE F, et al. A review on impacts of wind power uncertainties on power systems [J]. Proceedings of the CSEE, 2014, 34(29): 5029-5040.
- [5] 王伟胜, 王铮, 董存, 等. 中国短期风电功率预测技术现状与误差分析[J]. 电力系统自动化, 2021, 45(1): 17-27.
- WANG W S, WANG Z, DONG C, et al. Status and error analysis of short-term forecasting technology of wind power in China[J]. Automation of electric power systems, 2021, 45(1): 17-27.
- [6] PENG X S, LI C, JIA S Y, et al. A short-term wind power prediction method based on deep learning and multistage ensemble algorithm [J]. Wind energy, 2022, 25(9): 1610-1625.
- [7] ALMUTAIRI A, ALRUMAYH O. An intelligent deep learning based prediction model for wind power generation [J]. Computers and electrical engineering, 2022, 101: 108000.
- [8] ZHANG M, LI H B, DENG X. Inferential statistics and machine learning models for short-term wind power forecasting[J]. Energy engineering, 2022, 119(1): 237-252.
- [9] SASSER C, YU M L, DELGADO R. Improvement of wind power prediction from meteorological characterization with machine learning models [J]. Renewable energy, 2022, 183: 491-501.
- [10] WANG J M, ZHOU Q W, ZHANG X T. Wind power forecasting based on time series ARMA model [J]. IOP conference series: earth and environmental science, 2018, 199: 022015.
- [11] 凌立文, 张大斌. 组合预测模型构建方法及其应用研究综述[J]. 统计与决策, 2019, 35(1): 18-23.
- LING L W, ZHANG D B. A review of construction and application of combination forecast model [J]. Statistics & decision, 2019, 35(1): 18-23.
- [12] TASICARA OGLU A, UZUNOGLU M. A review of combined approaches for prediction of short-term wind speed and power [J]. Renewable and sustainable energy reviews, 2014, 34: 243-254.
- [13] 孙荣富, 张涛, 和青, 等. 风电功率预测关键技术及应用综述[J]. 高电压技术, 2021, 47(4): 1129-1143.
- SUN R F, ZHANG T, HE Q, et al. Review on key technologies and applications in wind power forecasting [J]. High voltage engineering, 2021, 47(4): 1129-1143.
- [14] 李贞, 崔丽艳, 陶颖军, 等. 基于博弈论赋权的光伏功率组合预测模型[J]. 电气技术, 2017(5): 24-29.
- LI Z, CUI L Y, TAO Y J, et al. The combined model for pv power forecasting based on combination weighting approach of game theory [J]. Electrical engineering, 2017(5): 24-29.
- [15] 陈宁, 沙倩, 汤奕, 等. 基于交叉熵理论的风电功率组合预测方法[J]. 中国电机工程学报, 2012, 32(4): 29-34, 22.
- CHEN N, SHA Q, TANG Y, et al. A combination method for wind power predication based on cross entropy theory [J]. Proceedings of the CSEE, 2012, 32(4): 29-34, 22.
- [16] ZHANG F, GUO Z M, SUN X H, et al. Short-term wind power prediction based on EMD-LSTM combined model [J]. IOP conference series: earth and environmental science, 2020, 514(4): 042003.
- [17] 王维高, 魏云冰, 滕旭东. 基于VMD-SSA-LSSVM的短期风电预测[J]. 太阳能学报, 2023, 44(3): 204-211.
- WANG W G, WEI Y B, TENG X D. Short-term wind power forecasting based on VMD-SSA-LSSVM [J]. Acta energiae solaris sinica, 2023, 44(3): 204-211.
- [18] 贾睿, 杨国华, 郑豪丰, 等. 基于自适应权重的CNN-LSTM&GRU组合风电功率预测方法[J]. 中国电力, 2022, 55(5): 47-56, 110.
- JIA R, YANG G H, ZHENG H F, et al. Combined wind power prediction method based on CNN-LSTM & GRU with adaptive weights [J]. Electric power, 2022, 55(5): 47-56, 110.
- [19] 张浩田, 温蜜, 李晋国, 等. 数据驱动的时间注意力卷积风电功率预测模型[J]. 太阳能学报, 2022, 43(10): 167-176.
- ZHANG H T, WEN M, LI J G, et al. Data driven time attention convolution wind power prediction model [J]. Acta energiae solaris sinica, 2022, 43(10): 167-176.
- [20] WANG Y R, WANG D C, TANG Y. Clustered hybrid wind power prediction model based on ARMA, PSO-SVM, and clustering methods[J]. IEEE access, 2020, 8: 17071-17079.
- [21] 刘帅, 朱永利, 张科, 等. 基于误差修正ARMA-GARCH模型的短期风电功率预测[J]. 太阳能学报, 2020, 41(10): 268-275.
- LIU S, ZHU Y L, ZHANG K, et al. Short-term wind power forecasting based on error correction ARMA-GARCH model[J]. Acta energiae solaris sinica, 2020, 41(10): 268-275.
- [22] CHANDRAN V, PATIL C K, MERLINE MANOHARAN A, et al. Wind power forecasting based on time series model using deep machine learning algorithms [J]. Materials today: proceedings, 2021, 47: 115-126.

- [23] GANAIE M A, HU M H, MALIK A K, et al. Ensemble deep learning: a review [J]. Engineering applications of artificial intelligence, 2022, 115: 105151.
- [24] DONG X B, YU Z W, CAO W M, et al. A survey on ensemble learning [J]. Frontiers of computer science, 2020, 14(2): 241-258.
- [25] RIBEIRO M T, SINGH S, GUESTRIN C. "Why should I trust you?": explaining the predictions of any classifier [C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco, California, USA, 2016: 1135-1144.
- [26] LIANG Y, LI S G, YAN C G, et al. Explaining the black-box model: a survey of local interpretation methods for deep neural networks [J]. Neurocomputing, 2021, 419: 168-182.

WIND POWER FORECASTING BASED ON INTERPRETABLE OPTIMAL STACKING MODEL

Qi Huanxing^{1,2}, Zhuo Yixin¹, Li Ling¹, Yin Linfei³, Qin Yiming¹, Meng Wenchuan⁴

(1. Guangxi Power Grid Dispatching Control Center, Nanning 530023, China;

2. Beihai Power Supply Bureau, Guangxi Power Grid, Beihai 536000, China;

3. School of Electrical Engineering, Guangxi University, Nanning 530004, China;

4. Energy Development Research Institute, China Southern Power Grid, Guangzhou 511458, China)

Abstract: High accuracy of wind power forecasting is an important support to ensure the balance of the power and load and stable operation of power system. In view of the trial-error and weak interpretative problems of current wind power forecasting algorithms in stack modeling, an interpretable optimal stacking model (IOSM) is proposed in this paper, which is applied to wind power forecasting. Firstly, establish an initial redundant base learner and interpret the feature weights. Further, construct a feature optimization metric that comprehensively measures model performance and computation cost, to optimize and select key features and train them to form optimized base learners. Finally, based on feature optimization metrics, the meta learner is established by the the optimized base learner. As above, the complete IOSM is constructed. The proposed algorithm is applied to typical wind farms in Guangxi. Compared with the optimal single model, the RMSE and MAE indexes of IOSM are reduced by 13.01% and 18.23% respectively. Compared with other mainstream combinatorial algorithms, the RMSE and MAE indexes of IOSM can be decreased by 8.24% and 10.28% respectively, while still reducing 142.38% modeling computation cost at least. The effectiveness and advancement of the proposed algorithm are verified, which provides a new idea and method for interpretability modeling of wind power forecasting.

Keywords: wind power forecasting; interpretability; stacking model; feature optimization; ensemble learning

附录

附表1 基学习器与元学习器的基本参数

Attached Tab. 1 Basic model parameters of base learners and meta learners

模型	学习器	训练算法	模型拓扑	激活函数、核函数等	损失函数	其他参数
机器学习模型	SVM	基学习器	序列最小二乘算法 (Sequential Least Squares, SLS)	support vector regression	核函数取径向基函数 (radial basis function, RBF)	RMSE 惩罚参数 C 设定为 1; epsilon 设定为 0.5; KFold 设定为 10
	KNN	基学习器	KD Tree	K 设定为 10	距离度量取欧拉距离 (euclidean distance)	RMSE KFold 设定为 10
	RF	基学习器	Bagging	由 100 个决策树组成 随机森林	最小子叶样本数 (mini leaf size) 取 4	RMSE 决策树最大分割数 (Maximum split) 取 100, KFold 设定为 10
非时序深度学习模型	MLP	基学习器	随机梯度下降算法	隐藏为 5 层, 神经元数依次为 50、200、400、200、50	激活函数取 Tanh 函数	RMSE 隐层第五层设置 dropout rate 取 0.05
	RBF	基学习器	梯度下降算法	最大神经元数量设定为 5000	径向基函数 (radial basis function, RBF)	RMSE spread 设定为 1
	DBN	基学习器、元学习器	对比散度算法、随机梯度下降算法	由 4 个首尾堆叠的受限玻尔兹曼机组成, 神经元数依次为 50、200、400、200、50	激活函数取 Tanh 函数	RMSE 隐层第五层设置 dropout rate 取 0.05
时序深度学习模型	RNN	基学习器	随机梯度下降算法	隐藏为 5 层, 神经元数依次为 50、200、400、200、50	激活函数取 Tanh 函数	RMSE 隐层第五层设置 dropout rate 取 0.05
	LSTM	基学习器	随机梯度下降算法	隐藏为 5 层, 神经元数依次为 50、200、400、200、50	激活函数取 Tanh 函数	RMSE 隐层第五层设置 dropout rate 取 0.05
	NARX	基学习器	随机梯度下降算法	隐藏为 5 层, 神经元数依次为 50、200、400、200、50	激活函数取 Tanh 函数	RMSE 正反馈延时向量长度为 3, 反馈延时向量长度为 3, 隐层第五层设置 dropout rate 取 0.05